



PROYECTO 003: DEEP LEARNING

Microestructura y Sistemas de Trading

Presenta

Alexander Sotomayor

Eddie Aguilar

Iñigo De Obeso

Estructura del Proyecto:

1. Resumen

Se desarrolló un sistema de trading algorítmico basado en ML, específicamente un modelo de clasificación con SVM (Máquinas de Vectores de Soporte), cuyo objetivo es generar señales de compra (BUY), venta (SELL) y espera (WAIT) en datos históricos de precios de AAPL a intervalos de 5 minutos.

El sistema fue complementado con un backtesting robusto, un periodo de optimización de parámetros e hiperparámetros y una evaluación de desempeño usando métricas financieras como el Sharpe Ratio, Sortino Ratio y Calmar Ratio y el rendimiento del portafolio.

2. Indicadores técnicos

Se emplearon tres indicadores técnicos para ayudar al algoritmo de machine learning a generar señales de trading:

1. **RSI**: Mide la velocidad y el cambio de los movimientos de precio. Indica si un activo está sobrecomprado (precio muy alto) o sobrevendido (precio muy bajo) comparado con su comportamiento reciente.
2. **Williams %R**: Mide el nivel actual del precio en relación con su rango máximo y mínimo en un periodo determinado. Es similar al RSI, pero en escala invertida.
3. **Ultimate Oscillator**: Es un indicador de momentum que combina tres periodos de tiempo diferentes para evitar señales falsas comunes en otros osciladores.

3. Optimización de Parámetros/Hiperparámetros

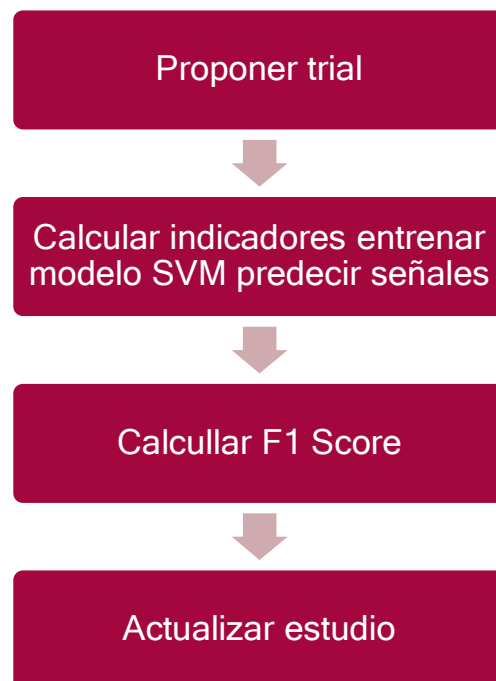
Study 1: Parámetros del dataset.

Para mejorar el desempeño del modelo SVM, se utilizó Optuna, una librería de optimización automática de hiperparámetros basada en búsqueda bayesiana y pruning inteligente.

Durante la primera ronda de optimización se optimizaron los siguientes hiperparámetros:

- rsi_window
- williams_lbp
- ultimate_window1, ultimate_window2, ultimate_window3
- C (coeficiente de penalización) para el modelo de SVM

Para la optimización de estos hiperparámetros, se definió como función objetivo la maximización del F1 Score macro promedio, asegurando un balance entre la precisión y la cobertura de las clases.



Study 2: Optimización del Backtesting.

Tras obtener un modelo optimizado, las señales generadas se evaluaron a través de un sistema de backtesting, considerando posiciones largas y cortas, reglas de stop-loss y take-profit.

Los parámetros optimizados fueron los siguientes:

- Stop loss
- Take profit
- Número de acciones por trade

Durante la optimización de estos parámetros, se definió como función objetivo la maximización del ratio de Calmar, que mide la rentabilidad ajustada por el drawdown máximo.


Hiperparámetro	Valor
Stop Loss	18.56%
Take Profit	27.43%
RSI	16
Ultimate	8, 17, 28
Williams	19
Numero de acciones	4,900
C (coeficiente de penalización)	34.51

4. Resultados

Para evaluar el rendimiento del portafolio se utilizaron las siguientes métricas:

1. Ratio de Calmar
2. Ratio de Sortino
3. Ratio de Sharpe
4. Rendimiento del portafolio

Se utilizó el valor de los T-Bills de EEUU como referencia para la tasa libre de riesgo utilizada en el cálculo de algunas de las métricas antes mencionadas. El valor actual es del 4.10%



Metrica	Valor
Ratio de Calmar	2.95
Ratio de Sharpe	1.76
Ratio de Sortino	2.21
Rendimiento	32.9%
Valor final del portafolio	\$1,329,020.01

5. Conclusiones

Dado a que el modelo se probó vía la metodología de backtesting cabe recalcar que los parámetros de dicho modelo están ajustados a la medida del dataset proporcionado. Este ejercicio fue con el propósito de implementar procesos de optimización y ajustes de modelos vía machine learning.

Adicionalmente, dado el comportamiento alcista y agresivo del activo subyacente la comparativa del modelo contra de dicho se vuelve más exigente, sin embargo, un retorno de 32.9% anualizado es bastante atractivo.

Los pasos a seguir serían probar dicho modelo con distintos datasets para probar su flexibilidad de tendencias y comportamientos de mercado para poder valorar su capacidad de rentabilidad.